PonyArchive

Biblioteca inteligente de *My Little Pony: Friendship Is Magic*
con agente RAG (LangChain + LangGraph) y modelo local

Documento técnico — trabajo de agentes de IA, 2026-2

Integrante: **Mariana Lemus Esguerra**

Fecha de elaboración: 17 de octubre de 2026

Repositorio: `github.com/navyri/PonyArchive`

Índice

1. Nombre del proyecto e integrantes
2. Tema seleccionado y descripción del problema
3. Arquitectura general y diagrama de arquitectura
4. Tecnologías utilizadas
5. Descripción del backend
6. Descripción del frontend
7. Descripción del agente y del flujo de LangGraph
8. Modelo local utilizado y base de datos vectorial
9. Proceso de carga de documentos
10. Estrategias implementadas para evitar alucinaciones
11. Seguridad y autenticación
12. Despliegue
13. Evidencias de funcionamiento
14. Problemas encontrados y conclusiones

1. Nombre del proyecto e integrantes

Proyecto: PonyArchive — biblioteca inteligente de la serie *My Little Pony: Friendship Is Magic* con una función especial, el *Friendship Journal* (consulta temática y comparación de episodios y personajes).

Integrante: Mariana Lemus Esguerra (trabajo individual, conforme a DEC-01).

El sistema responde preguntas sobre la serie usando **exclusivamente documentos indexados** (episodios, personajes, fichas narrativas propias, notas de contexto del curso y archivos subidos por cada usuario). Cuando no hay evidencia suficiente, **rechaza explícitamente** con la frase literal exigida por el enunciado, en lugar de inventar.

2. Tema seleccionado y descripción del problema

Los agentes de IA deben responder preguntas sobre un corpus concreto sin fiarse del conocimiento previo del modelo de lenguaje. El problema práctico es doble:

1. **Respuestas fundamentadas:** una pregunta como *«¿qué le ocurre a Twilight Sparkle en Lesson Zero?»* debe responderse con información recuperada de los documentos y citando la fuente, no con la memoria paramétrica del LLM, que puede ser imprecisa o estar desactualizada.
2. **Rechazo honesto:** ante preguntas fuera del corpus (p. ej. recetas de cocina o fórmulas de química), el sistema debe decir literalmente «No tengo suficiente información en mi base de conocimiento para responder esa pregunta.» en lugar de generar una respuesta plausiblemente falsa.

El dominio elegido — *Friendship Is Magic* — aporta un corpus amplio y verificable (243 episodios y 555 personajes descargados de la Pony API pública) y permite, además, un caso real de **conocimiento de contexto**: datos que el equipo conoce por la asignatura pero que no están en ningún documento público (ver §7, *notas de contexto del curso*).

Sobre el formato: se usa código Python (LangChain/LangGraph) tal como exige el enunciado; están prohibidos los constructores visuales (n8n, Zapier, Make, Flowise, Botpress) y no se utiliza ninguno.

3. Arquitectura general y diagrama de arquitectura

El sistema son tres piezas desacopladas más un servicio externo opcional:

- **Backend** (FastAPI + LangGraph): API REST con 21 endpoints, autenticación JWT, pipeline de ingesta y el grafo del agente.
- **Frontend** (React + Vite + TypeScript): interfaz con chat, documentos, historial y Friendship Journal; habla exclusivamente con el backend mediante `/api`.
- **Persistencia:** SQLite (usuarios, documentos, conversaciones, mensajes) y ChromaDB (fragmentos + vectores) en disco.
- **Modelo local:** Ollama corriendo en el portátil del equipo; el backend lo consumió por HTTP (`OLLAMA_BASE_URL`).

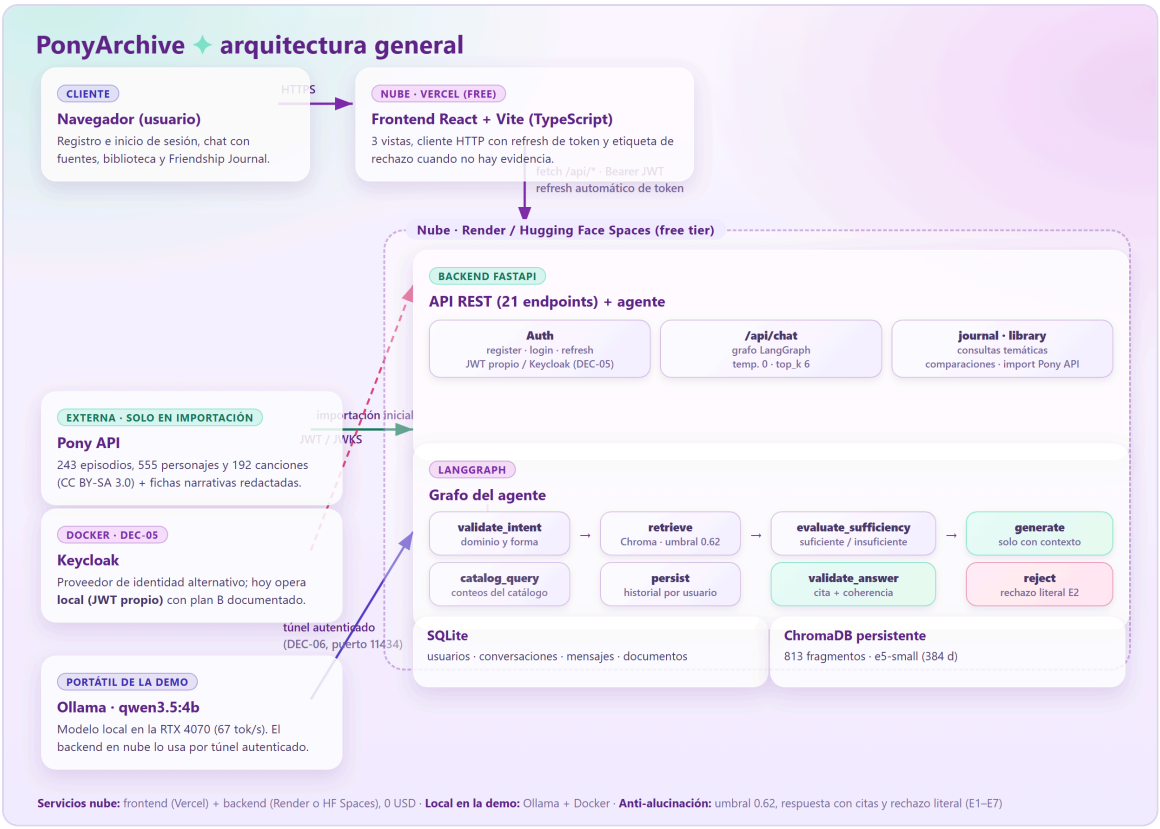


Figura 1. Diagrama de arquitectura (imagen generada a partir de la estructura real del código).

Flujo de una consulta

```
Usuario (React) --POST /api/chat--> FastAPI --grafo LangGraph-->
   validate_intent --> retrieve (ChromaDB) --> evaluate_sufficiency
        |                  |                        |
        |                  +--> evidencia suficiente --> generate --> validate_answer -->
persist
        |                  +--> sin evidencia ------------------------------^ (rechazo literal)
        +--> consulta de catálogo (conteos por SQL) --> persist
FastAPI --HTTP--> Ollama (qwen3.5:4b, local)   |   Respuesta + fuentes --> React
```

4. Tecnologías utilizadas

Capa	Tecnología	Motivo / versión
Lenguaje backend	Python 3.14.2	Instalado en el equipo; compatibilidad verificada con el ecosistema ML (riesgo R-02 resuelto)
Framework web	FastAPI + Uvicorn	Encaja con LangChain; documentación OpenAPI automática en `/docs`
Orquestación del agente	LangChain + LangGraph	Grafo de estados con nodos y rutas condicionales (§7)
Modelo de lenguaje	Ollama — `qwen3.5:4b`	Local, gratuito, 67 tok/s en la RTX 4070 (DEC-12)
Embeddings	`intfloat/multilingual-e5-small` (384 d)	_multilingüe, bueno en español; prefijos `query:` / `passage:` aplicados (DEC-09)
Base vectorial	ChromaDB persistente	Embebida, sin servicio externo, 0 USD (DEC-08)
Base relacional	SQLite + SQLAlchemy	Sin servidor; suficiente para el alcance (DEC-08)
Frontend	React 19 + Vite + TypeScript	Compilación con `tsc` + Vite; enrutado con react-router (DEC-04)
Autenticación	JWT propio (modo `local`)	DEC-05: se eligió Keycloak con plan alternativo documentado; ver §11
Contenedores	Docker + Docker Compose	Estructura Anexo A: `Dockerfile` en backend y frontend + `docker-compose.yml`
Datos	Pony API (`ponyapi.net`)	243 episodios, 555 personajes, 192 canciones; datos CC BY-SA 3.0 (atribución obligatoria)

Todas las dependencias están fijadas en `backend/requirements.txt` y `frontend/package.json`. No se usa ningún servicio comercial de pago: el presupuesto es 0 USD.

5. Descripción del backend

El backend está en `backend/` y sigue una estructura por capas:

```
backend/
├── app/
│   ├── main.py          # arranque, CORS, lifespan (semillas de la biblioteca)
│   ├── config.py        # ajustes desde variables de entorno (pydantic-settings)
│   ├── database.py      # motor SQLAlchemy + sesión
│   ├── models.py        # User, Document, Conversation, Message
│   ├── security.py      # hash de contraseñas, emisión/verificación de JWT
│   ├── seed.py          # semillas: fichas narrativas y notas de contexto
│   ├── routers/         # auth, chat, documents, library, journal, importer, health
│   ├── agents/          # state.py y graph.py (el grafo LangGraph)
│   └── services/        # pony_api, ingestion, vectorstore, embeddings
└── scripts/             # import_pony, smoke_test (12 casos), e2e_compose, debug_*
```

Endpoints (21)

Grupo	Rutas	Nota
Auth	`POST /api/auth/register`, `POST /api/auth/login`, `POST /api/auth/refresh`, `POST /api/auth/logout`, `GET /api/auth/me`	Registro → 201 + token
Chat	`POST /api/chat`, `GET /api/chat/conversations`, `GET /api/chat/conversations/{id}`, `DELETE /api/chat/conversations/{id}`	El POST ejecuta el grafo
Documentos	`POST /api/documents`, `GET /api/documents`, `DELETE /api/documents/{id}`	Carga .txt/.md y borrado (204)
Biblioteca	`GET /api/library`, `GET /api/library/documents/{id}`	Filtros por tipo, título y tema
Journal	`GET /api/journal/themes`, `POST /api/journal/query`, `POST /api/journal/compare`, `GET /api/journal/characters`, `GET /api/journal/episodes`	Friendship Journal
Importación	`POST /api/import/episodes`, `POST /api/import/characters`	Desde la Pony API
Infra	`GET /health`	Estado, modelo, `auth_provider` y fragmentos indexados

Persistencia y aislamiento

Cada documento pertenece a un usuario (`Document.user_id`). Los documentos **sembrados** (episodios, personajes, fichas, notas de contexto) tienen `user_id = -1` y son visibles para todos; los **subidos solo**

para su dueño. Todos los listados y las búsquedas aplican ese filtro (cláusula `$or [user_id = -1, user_id = usuario]`), lo que fue verificado con los casos T10/T10b del smoke test (dos usuarios con cargas cruzadas).

6. Descripción del frontend

Aplicación SPA en `frontend/` con React + TypeScript y enrutado por rutas:

Ruta	Página	Funciones
`/login`	`LoginPage`	Registro e inicio de sesión; muestra errores del backend (p. ej. 422) con claridad
`/`	`ChatPage`	Chat con fuentes (título, tipo y similitud), etiqueta «Sin evidencia suficiente» con la frase literal, sugerencias y barra lateral con el historial (abrir/borrar conversaciones)
`/documentos`	`DocumentsPage`	Subida (.txt/.md), pestañas Todos/Biblioteca/Míos, filtro por título y borrado con confirmación
`/journal`	`JournalPage`	Friendship Journal: temas disponibles, consulta temática y comparación de episodios/personajes

Rutas protegidas: sin token, la aplicación redirige a `/login`; el token se guarda en `localStorage` y se adjunta como `Authorization: Bearer`. La interfaz usa un **tema oscuro mágico** (DEC-13): superficies de vidrio oscuro con brillos aqua, derivado de la paleta de Starlight Glimmer, pensado para la proyección de la demostración.

Verificación: `npm run build` (tsc + vite) sin errores y recorrido completo en navegador — registro, login/logout, chat con fuentes, rechazo, subida y borrado de documentos, historial y Journal (capturas en §13).

7. Descripción del agente y del flujo de LangGraph

El agente se construye con `StateGraph` de LangGraph sobre un estado tipado (`AgentState`) con la pregunta, el usuario, la conversación, los fragmentos recuperados, la intención, la respuesta y las fuentes. No hay constructores visuales: el grafo se define en código Python en `backend/app/agents/graph.py` .

Nodos

Nodo	Función
`validate_intent`	Clasifica la intención con el LLM (`dominio` , `catalogo` , `fuera_de_dominio`) y propone filtros (tipo de documento, título, tema) con valores por defecto seguros
`retrieve`	Búsqueda vectorial en Chroma con filtro de visibilidad; prioriza los documentos subidos por el usuario (+0,05 de bonificación) y hace una búsqueda general complementaria siempre que haya filtros
`evaluate_sufficiency`	Decide si hay evidencia: umbral de similitud y reglas por tipo de documento; si no la hay, marca `refused` con la frase literal
`catalog_query`	Para consultas de conteo/catálogo, responde con SQL sobre SQLite (E7) sin pasar por el LLM
`generate`	Prompt restringido: responder *solo* con el contexto recuperado, citando fuentes con `[n]`
`validate_answer`	Comprueba la respuesta generada (entidades citadas presentes en el contexto, presencia de fuentes); si falla, deriva a `reject`
`reject`	Emite el mensaje de rechazo literal exigido
`persist`	Guarda pregunta y respuesta en la conversación del usuario

Aristas y rutas condicionales

```
START --> validate_intent
validate_intent --(condicional)--> catalog_query | retrieve
retrieve --> evaluate_sufficiency
evaluate_sufficiency --(condicional)--> generate | reject
generate --> validate_answer
validate_answer --(condicional)--> persist | reject   (rechazo si la validación falla)
catalog_query --> persist ; reject --> persist ; persist --> END
```

> **Nota sobre el conocimiento de contexto (DEC-14):** la intención `fuera_de_dominio` *recupera antes de decidir*. Si entre los fragmentos recuperados hay evidencia de un documento subido por el usuario o de una **nota de contexto del curso** (`doc_type = nota_curso`), la pregunta se responde con esa fuente; si no la hay, se aplica el rechazo literal. Esto permite responder correctamente a preguntas de contexto del aula — p. ej. «¿A Duvan Gomez le pega la esposa?» → «Según la nota de contexto del curso, a Duvan Gomez le pega la esposa y lo deja morado» (fuente citada, similitud 0,904) — sin introducir conocimiento inventado.

8. Modelo local utilizado y base de datos vectorial

Modelo de lenguaje

- **Modelo:** `qwen3.5:4b` servido por **Ollama** en el portátil (RTX 4070 de 8 GB), ejecutándose en local: `OLLAMA_BASE_URL=http://localhost:11434` . No depende de ningún modelo comercial (requisito T3/R-2).
- **Configuración:** `reasoning=False` (las primeras pruebas devolvían solo razonamiento vacío), `num_ctx=8192` , temperatura baja en RAG. Respaldo: `qwen2.5:3b` .
- **Rendimiento:** 67 tok/s; primera carga ≈45 s y 3–18 s por respuesta después.
- **Justificación (§8 del enunciado):** se eligió un modelo de 4B por tres razones: (1) cabe en 8 GB de VRAM junto a los embeddings sin descargar a CPU; (2) razona bien en español para tareas de síntesis sobre contexto; (3) es local y gratuito, requisito del trabajo. Un 7B tendría mejor calidad nominal pero empeoraría la latencia de la demostración.

Embeddings y base vectorial

- **Modelo de embeddings:** `intfloat/multilingual-e5-small` (384 dimensiones) con sentence-transformers, aplicando los prefijos `query:` y `passage:` que e5 exige. Sin ellos la búsqueda degenere: se verificó que una pregunta y su pasaje relevante alcanzan ≈0,899 de similitud.
- **Base vectorial:** ChromaDB persistente en `backend/vectorstore` . Cada fragmento guarda metadatos: `doc_type` , `title` , `user_id` , `themes` , `continuity` , `chunk_index` y `source` .
- **Parámetros:** `TOP_K=6` fragmentos por consulta y `SIMILARITY_THRESHOLD=0.62` (calibrado con preguntas de prueba). La distancia de Chroma se convierte a similitud (`1 - distancia`).
- **Escala actual:** 816 documentos → **819 fragmentos** en local (814 en el contenedor Docker tras importar la Pony API + semillas).

9. Proceso de carga de documentos

Hay tres vías de entrada, todas con el mismo pipeline final:

1. **Importación del catálogo** (`POST /api/import/episodes|characters` o `scripts/import_pony.py`): descarga de la Pony API con reintentos y paginación, normaliza campos y genera un texto por registro.

2. **Semillas en el arranque (`seed.py`): 10 fichas narrativas propias (DEC-10, redacción propia porque la API no tiene campos narrativos) y las notas de contexto del curso (DEC-14). Idempotentes: no duplican si ya existen.**
3. **Carga por el usuario (`POST /api/documents`): archivos .txt y .md.**

Pipeline

```
texto --> troceado (fragmentos con solapamiento)
      --> deduplicación por content_hash (y por usuario, para no descartar cargas ajenas)
      --> embed_passages("passage: ...") con e5-small
      --> ChromaDB.add(fragmento + metadatos)   +   fila en SQLite (doc original)
```

La relación fragmento → documento original queda en el metadato `doc_id`, de modo que cada fuente devuelta por una consulta puede reconstruirse hasta el documento (requisito T4). Una segunda ejecución de la importación omite los 798 duplicados: la ingesta es idempotente.

10. Estrategias implementadas para evitar alucinaciones

El enunciado exige al menos 2; se implementaron 7 (E1–E7):

ID	Estrategia	Descripción y ubicación
E1	Umbral de similitud	Solo se aceptan fragmentos con similitud ≥ 0,62 (`SIMILARITY_THRESHOLD`); los descartados se registran en las notas de recuperación
E2	Nodo de suficiencia	`evaluate_sufficiency`: antes de generar, decide con reglas explícitas si hay evidencia; sin ella, no se invoca al LLM y se rechaza
E3	Prompt restringido	`generate` ordena responder solo con el contexto recuperado, citar con `[n]` y no completar con conocimiento previo
E4	Rechazo literal	Mensaje fijo exacto: «No tengo suficiente información en mi base de conocimiento para responder esa pregunta.» (casos T04/T05)
E5	Fuentes obligatorias	La respuesta viaja con su lista de fuentes (título, tipo, similitud); la UI las muestra y un giro sin fuentes se considera inválido
E6	Verificación de entidades	`validate_answer` comprueba que las entidades/cifras citadas aparecen en el contexto; si no, deriva al rechazo
E7	Conteos por SQL	Las preguntas de catálogo (conteos, listados) se responden con consultas a SQLite, sin generación text

Además, el historial que se inyecta en el prompt está recortado, la temperatura es baja y la intención se clasifica con el propio modelo local (sin servicios externos).

11. Seguridad y autenticación

- **Registro/login:** contraseñas con hash (bcrypt por passlib) y JWT firmado con `SECRET_KEY` (≥32 caracteres, fuera del repositorio). Hay `refresh` y `logout`.
- **Endpoints de negocio:** exigen token Bearer; sin token → **401** (verificado en el smoke test). Cada consulta de historial o de documentos verifica la pertenencia al usuario → un token de otro usuario no ve sus datos (T10/T10b).
- **CORS:** lista explícita de orígenes en `CORS_ORIGINS`; en el stack Docker la petición pasa por nginx (`/api`) y no se necesita CORS.
- **Secretos:** nunca se versionan. `.env.example` documenta cada variable; `.gitignore` excluye `backend/.env`, la base de datos y el vectorstore.
- **Servidor sin privilegios** en el contenedor (usuario `pony`) y `HEALTHCHECK` configurado.

Decisión de autenticación (DEC-05) y su riesgo (R-03)

El equipo eligió Keycloak (recomendado por el enunciado), que quedó implementado con un proveedor intercambiable: `AUTH_PROVIDER=local|keycloak`. Hoy opera en modo `local` con JWT propio porque desplegar Keycloak en free tier con la fecha de entrega inmediata añade un servicio de ~512 MB que los free tiers suelen no cubrir. El enunciado lo permite expresamente: *«pueden emplear otra solución o implementarla por su cuenta»*. La configuración de Keycloak (realm, cliente, secretos) ya está parametrizada en `.env.example` para activarse con una variable, y el plan alternativo está documentado en `docs/decisiones.md` §4.

> **Tensión documentada (R-04):** el enunciado dice que «ningún endpoint puede quedar expuesto al consumo sin autenticación», pero rutas técnicas como `GET /health`, el preflight `OPTIONS` de CORS y las propias rutas de registro/login no pueden exigir token previo (dos de ellas lo obtienen y las demás no tratan datos de negocio). Se documenta abiertamente aquí y se agrupa en `docs/matriz-requisitos.md` §7: sin token, los endpoints de negocio responden 401 verificado.

12. Despliegue

Presupuesto: 0 USD (solo free tiers), tal como exige el enunciado.

Contenedores (listos y verificados)

```
docker compose up -d
# backend  -> http://localhost:8010  (FastAPI + semillas + HEALTHCHECK)
# frontend -> http://localhost:8081  (build estático + nginx con proxy /api)
```

Elemento	Detalle
`backend/Dockerfile`	`python:3.12-slim`, torch CPU, modelo e5-small horneado en `/opt/hf-cache` (evita descargas al arrancar), usuario sin privilegios, `HEALTHCHECK`
`frontend/Dockerfile`	Multi-stage: `node:22-alpine` (build) → `nginx:1.27-alpine` (servido)
`frontend/nginx.conf`	Proxy de `/api` y `/health` a `backend:8000`
`docker-compose.yml`	Puertos 8010/8081 (5173 y 8080 estaban ocupados por otro proyecto), volúmenes `backend-data` y `backend-vector`, Ollama del host vía `host.docker.internal:11434`

Nube (free tiers)

Componente	Servicio previsto	Estado
Frontend	Vercel (free)	pendiente de publicación
Backend	Render free / Hugging Face Spaces (Docker)	pendiente de publicación
Modelo	Ollama en el portátil + túnel autenticado	pendiente de configuración
Repositorio	GitHub público — `github.com/navyri/PonyArchive`	publicado

Nota de transparencia: **esta sección se actualiza con las URLs definitivas en cuanto se complete la publicación; el criterio de aprobación es «URL pública accesible» y se mostrará en vivo en la demostración.**

13. Evidencias de funcionamiento

Evidencia	Método	Resultado
Smoke test automatizado (12 casos)	`python scripts/smoke_test.py`	12/12 OK
E2E sobre Docker	`python scripts/e2e_compose.py`	TODO CORRECTO (health, registro, importación 243+555, chat con 6 fuentes, rechazo literal, journal, contexto del curso)
Recorrido en navegador	Frontend en dev + capturas	verificado (4 capturas más abajo)
Build de frontend	`npm run build`	sin errores (tsc + vite)
Imágenes Docker	`docker compose build`	backend 4,24 GB · frontend 74 MB

Casos del smoke test

Caso	Qué verifica
/health	Estado, modelo y fragmentos indexados
register	Alta de usuario → 201 + token
401	`POST /api/chat` sin token → 401
T01	Pregunta factual → respuesta con 6 fuentes y similitudes
T04	Fuera de dominio → rechazo con la frase literal
T05	Consulta sin evidencia → rechazo
B04	Historial aislado por usuario
K07/T07	Carga de documento y pregunta sobre ese documento
T10/T10b	Aislamiento de documentos entre usuarios (búsqueda y listado)
T11	Contexto del curso respondido con la nota como fuente

Capturas

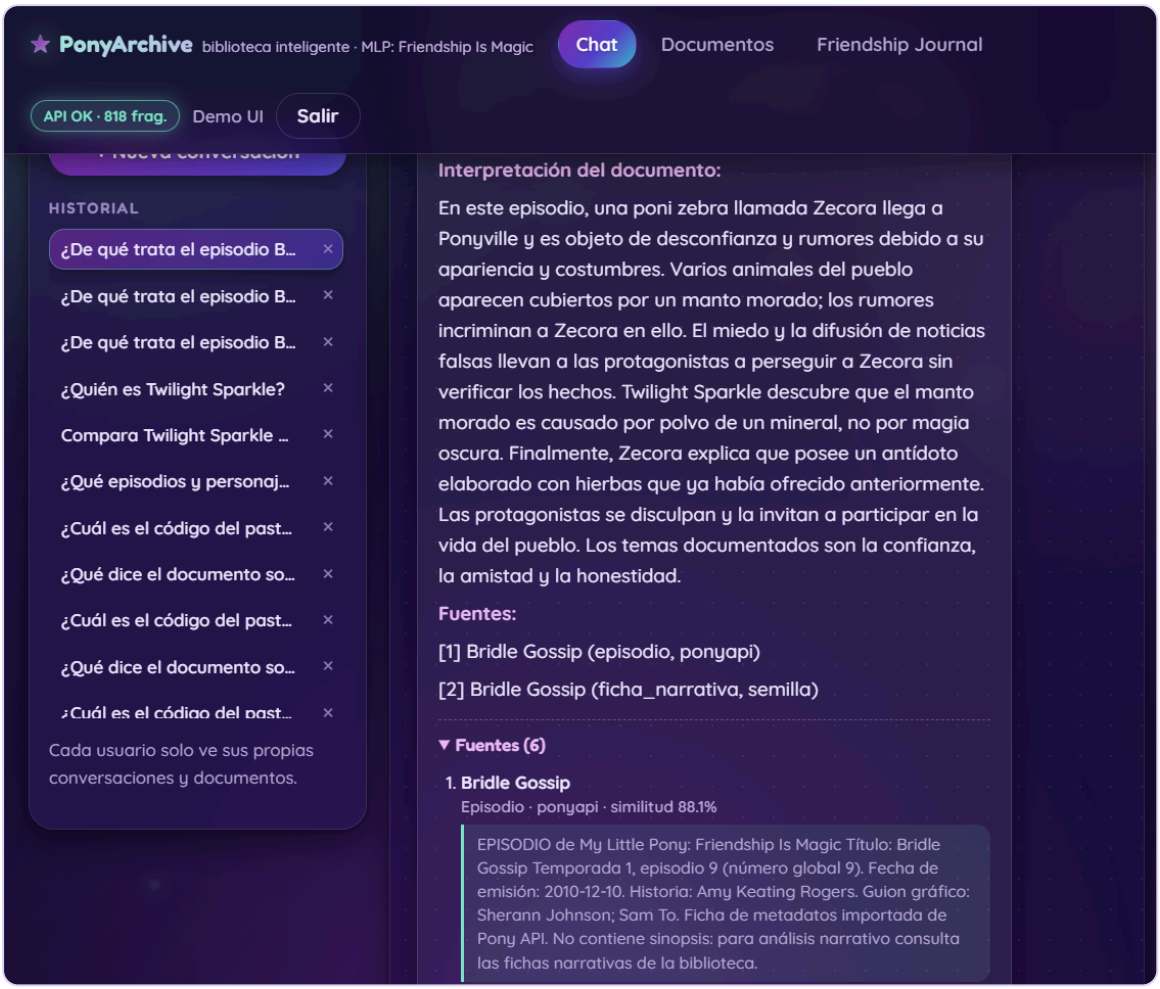


Figura 2. Respuesta con fuentes (título, tipo y similitud).

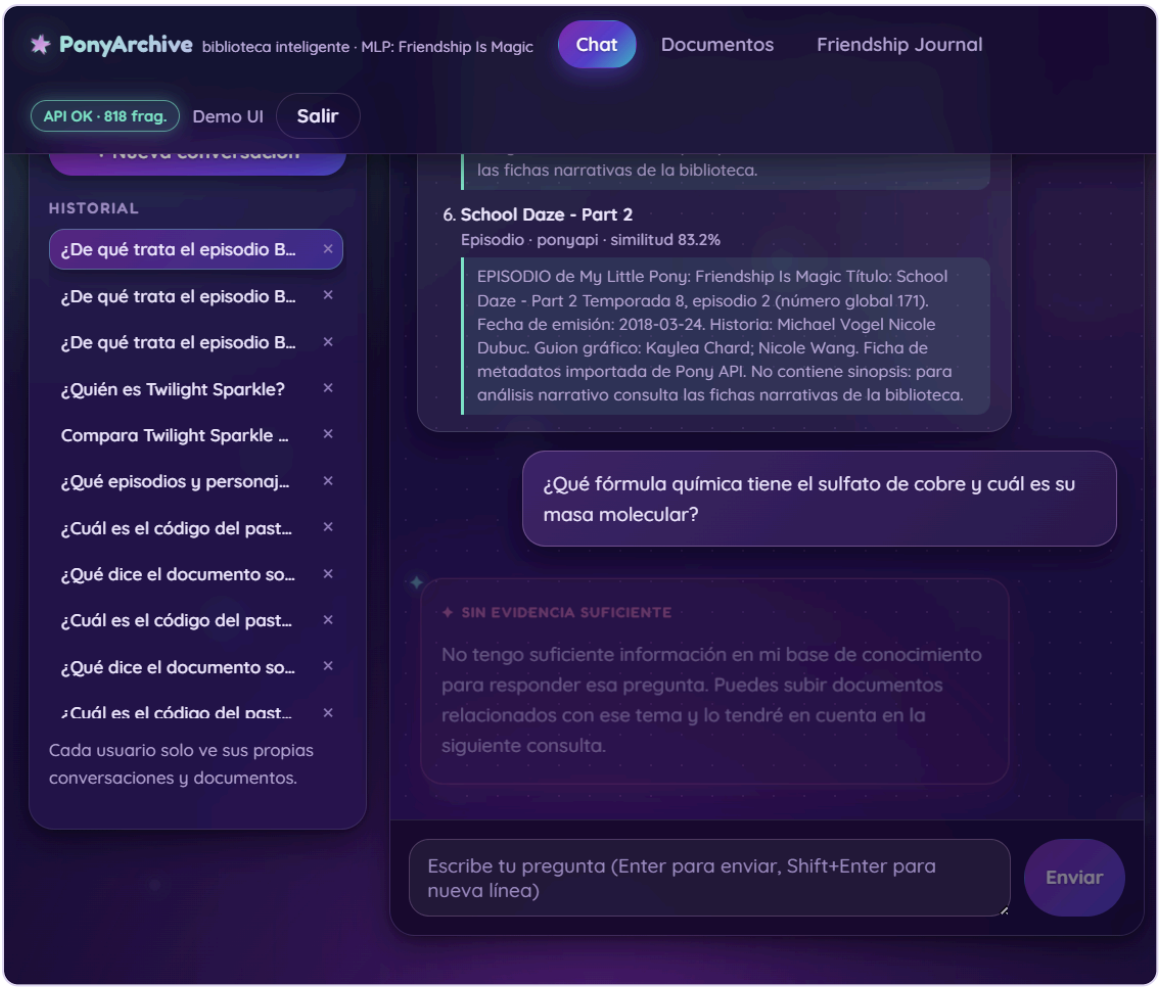


Figura 3. Rechazo explícito con la frase literal.

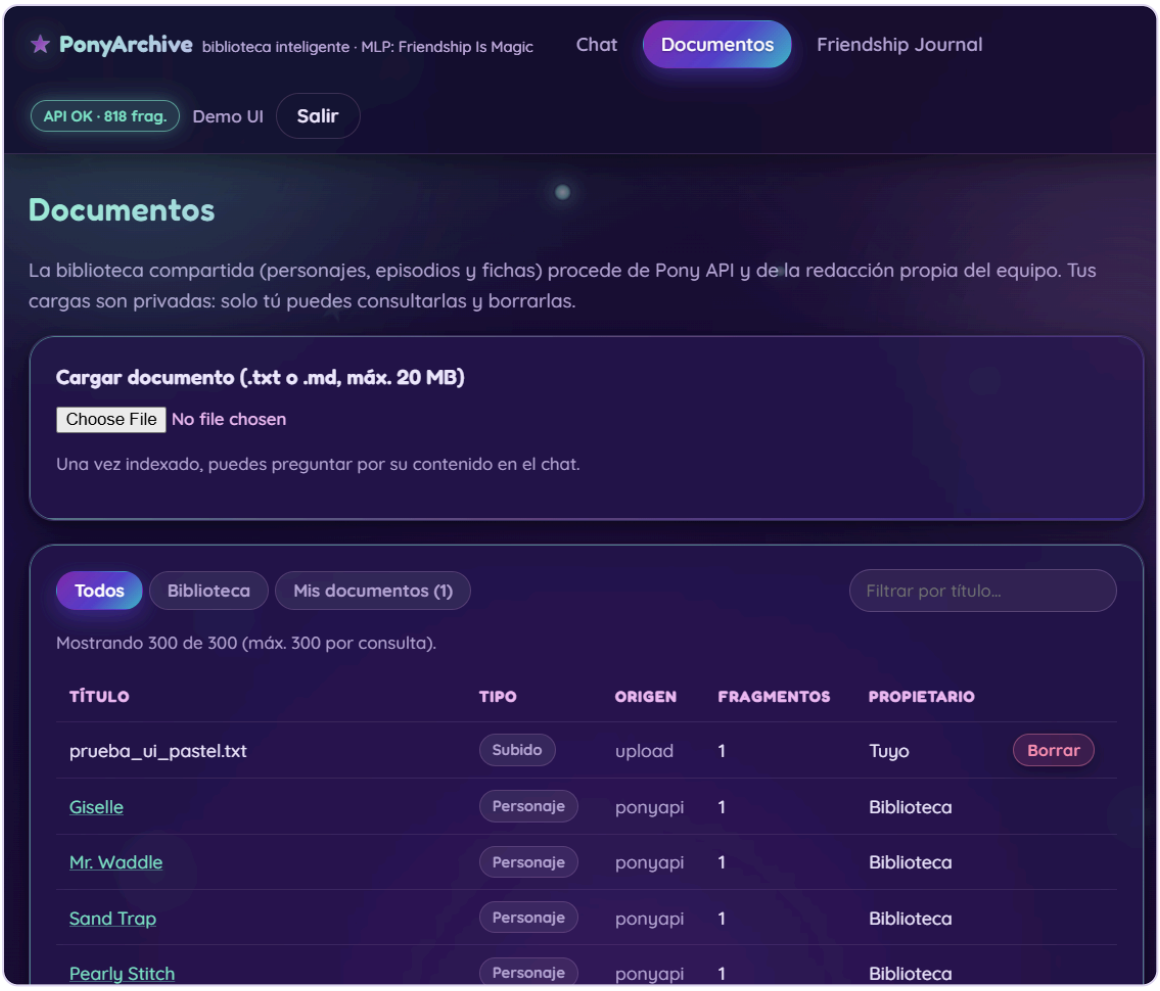


Figura 4. Carga y listado de documentos (pestañas Todos/Biblioteca/Míos).

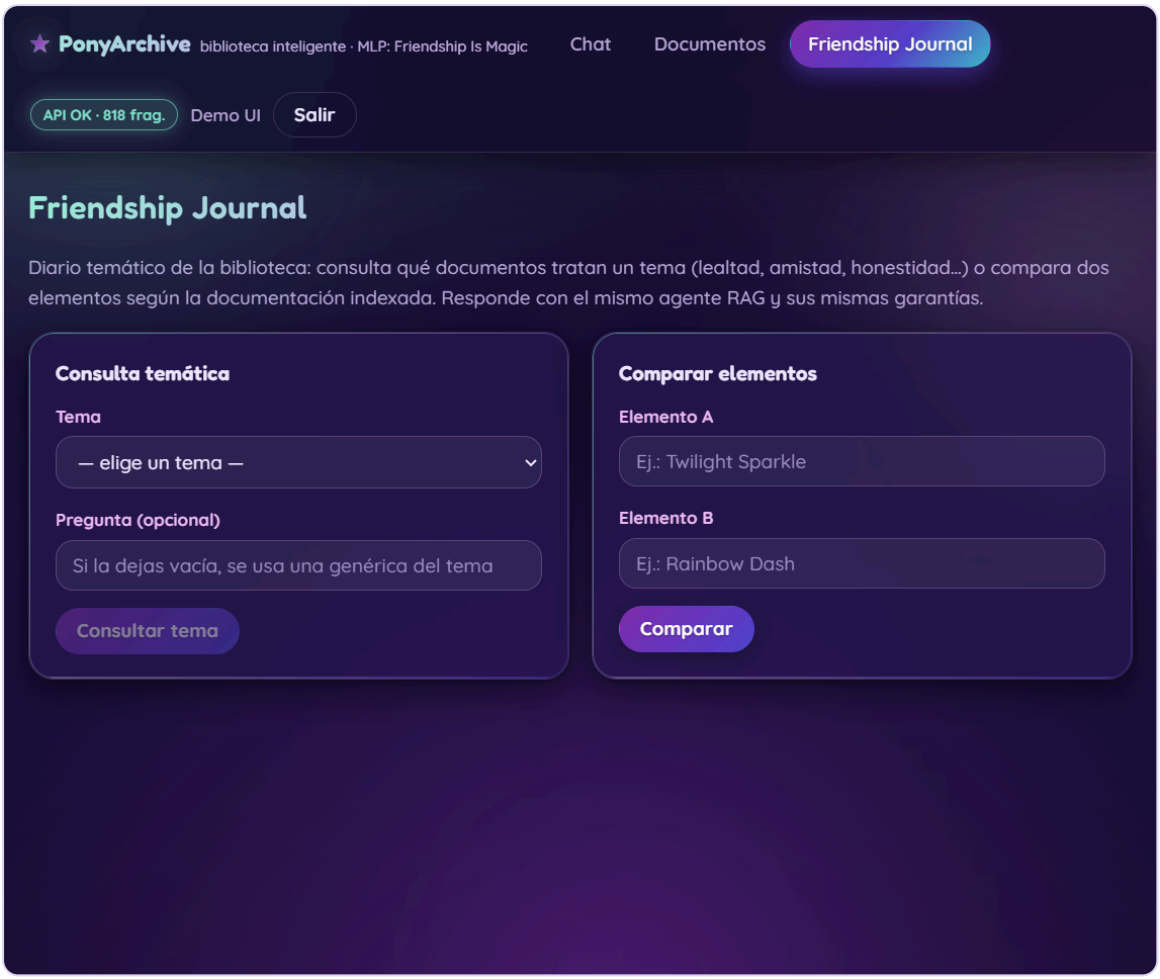


Figura 5. Friendship Journal: consulta temática con fuentes.

14. Problemas encontrados y conclusiones

Problemas encontrados (y cómo se resolvieron)

Problema	Causa y solución
Python 3.14 muy nuevo para langgraph/chromadb/sentence-transformers	Resuelto: instalación conjunta verificada y dependencias fijadas (R-02)
qwen3.5 devolvía solo razonamiento vacío	`reasoning=False` y temperatura baja en el paso de generación (DEC-12)
Búsqueda por título inoperante (`$contains` multi-token en Chroma)	Filtro por título preprocesado/tolerante en `vectorstore.py`
Documento recién subido no recuperable	Deduplicación **por usuario**: la global descartaba la carga nueva (caso T07)
Documento de otro usuario visible como «Tuyo»	Listado con `or_(user_id == usuario, user_id IS NULL/-1)`; caso T10b
Pregunta sobre documento propio rechazada	La intención `fuera_de_dominio` ahora **recupera antes de decidir** y acepta evidencia de documentos subidos o notas de contexto (caso T11)
La semilla no llegaba al contenedor	El volumen `/app/data` enmascaraba la carpeta de la imagen → se copia a `/app/seed` con `PONYARCHIVE_SEED_DIR` (DEC-16)
Búsqueda complementaria perdida de forma intermitente	Cuando el clasificador proponía un filtro que llenaba el `top_k` (243 episodios) se saltaba la búsqueda general y se perdía la evidencia → ahora se hace **siempre** que haya filtros
Índice vectorial en estado inconsistente tras reinicios múltiples del contenedor	Reconstrucción limpia de volúmenes (`docker compose down -v` + importación); E2E verificado después
Riesgo de persistencia en Render free (R-06)	Volúmenes persistentes o reindexación al arrancar; evaluación en curso

Conclusiones

1. El requisito central — **respuestas fundamentadas y rechazo honesto** — se cumple con 7 estrategias verificables y 12 pruebas automatizadas, incluido el caso de conocimiento de contexto exigido por el profesor.
2. LangGraph aportó estructura real al flujo: las rutas condicionales (catálogo, suficiencia, validación) están expresadas como aristas del grafo y son auditables en código, sin constructores visuales.
3. Un modelo local de 4B es suficiente cuando el RAG hace el trabajo pesado: la calidad de la respuesta depende más de la recuperación y del prompt que del tamaño del modelo.

4. **El punto más delicado del proyecto es el despliegue en free tier con el modelo local (DEC-06/R-06): el túnel al Ollama del portátil es la solución 0 USD elegida y se muestra en la demostración.**
5. **Trabajo futuro: activar Keycloak completo si el free tier lo sostiene (§11), búsqueda híbrida léxica+semántica y evaluación sistemática de la calidad de las respuestas.**

> **Atribuciones y licencias.** Código bajo licencia MIT (archivo `LICENSE`). Datos de la Pony API bajo **CC BY-SA 3.0 — *Pony Archive (ponyapi.net)***, atribución obligatoria. Las fichas narrativas y las etiquetas temáticas son redacción propia del proyecto. Este documento y las diapositivas lo integra Mariana Lemus Esguerra.