PonyArchive

Biblioteca inteligente de *My Little Pony: Friendship Is Magic* con agente RAG (LangChain + LangGraph) y modelo local.

Documento técnico — trabajo de agentes de IA, 2026-2 Integrante: **Mariana Lemus Esguerra** Fecha de elaboración: 18 de octubre de 2026 Repositorio: `github.com/navyri/PonyArchive`

Índice

1. Nombre del proyecto e integrantes
2. Tema seleccionado y descripción del problema
3. Arquitectura general y diagrama de arquitectura
4. Tecnologías utilizadas
5. Descripción del backend
6. Descripción del frontend
7. Descripción del agente y del flujo de LangGraph
8. Modelo local utilizado y base de datos vectorial
9. Proceso de carga de documentos
10. Estrategias implementadas para evitar alucinaciones
11. Seguridad y autenticación
12. Despliegue
13. Evidencias de funcionamiento
14. Problemas encontrados y conclusiones

---

1. Nombre del proyecto e integrantes

Proyecto: PonyArchive — biblioteca inteligente de la serie *My Little Pony: Friendship Is Magic* (generación G4, 2010-2019), centrada en un **agente RAG** (LangChain + LangGraph) que responde sobre su corpus indexado con las fuentes citadas y rechazo explícito cuando la evidencia no alcanza.

Integrante: Mariana Lemus Esguerra (trabajo individual).

El sistema responde preguntas sobre la serie usando **exclusivamente documentos indexados** (episodios, personajes, canciones, fichas narrativas propias, notas de contexto del curso y archivos subidos por cada

usuario). Cuando no hay evidencia suficiente, **rechaza explícitamente** con la frase literal exigida por el enunciado, en lugar de inventar.

2. Tema seleccionado y descripción del problema

Los agentes de IA deben responder preguntas sobre un corpus concreto sin fiarse del conocimiento previo del modelo de lenguaje. El problema práctico es doble:

1. **Respuestas fundamentadas:** una pregunta como *«¿qué le ocurre a Twilight Sparkle en Lesson Zero?»* debe responderse con información recuperada de los documentos y citando la fuente, no con la memoria paramétrica del LLM, que puede ser imprecisa o estar desactualizada.
2. **Rechazo honesto:** ante preguntas fuera del corpus (p. ej. recetas de cocina o fórmulas de química), el sistema debe decir literalmente **«No tengo suficiente información en mi base de conocimiento para responder esa pregunta.»** en lugar de generar una respuesta plausiblemente falsa.

El dominio elegido — *Friendship Is Magic* — aporta un corpus amplio y verificable (243 episodios, 555 personajes y 192 canciones descargados de la Pony API pública, con prosa de la wiki de Fandom) y permite, además, un caso real de **conocimiento de contexto**: datos que se conocen por la asignatura pero que no están en ningún documento público (ver §7, *notas de contexto del curso*).

Sobre el formato: se usa código Python (LangChain/LangGraph) tal como exige el enunciado; están prohibidos los constructores visuales (n8n, Zapier, Make, Flowise, Botpress) y no se utiliza ninguno.

3. Arquitectura general y diagrama de arquitectura

El sistema son tres piezas desacopladas más un servicio externo opcional:

- **Backend** (FastAPI + LangGraph): API REST con 17 endpoints, autenticación JWT, pipeline de ingesta y el grafo del agente.
- **Frontend** (React + Vite + TypeScript): interfaz con chat, documentos e historial; habla exclusivamente con el backend mediante `/api`.
- **Persistencia:** SQLite (usuarios, documentos, conversaciones, mensajes) y ChromaDB (fragmentos + vectores) en disco.
- **Modelo local:** Ollama corriendo en el portátil del equipo; el backend lo consume por HTTP (`OLLAMA_BASE_URL`).

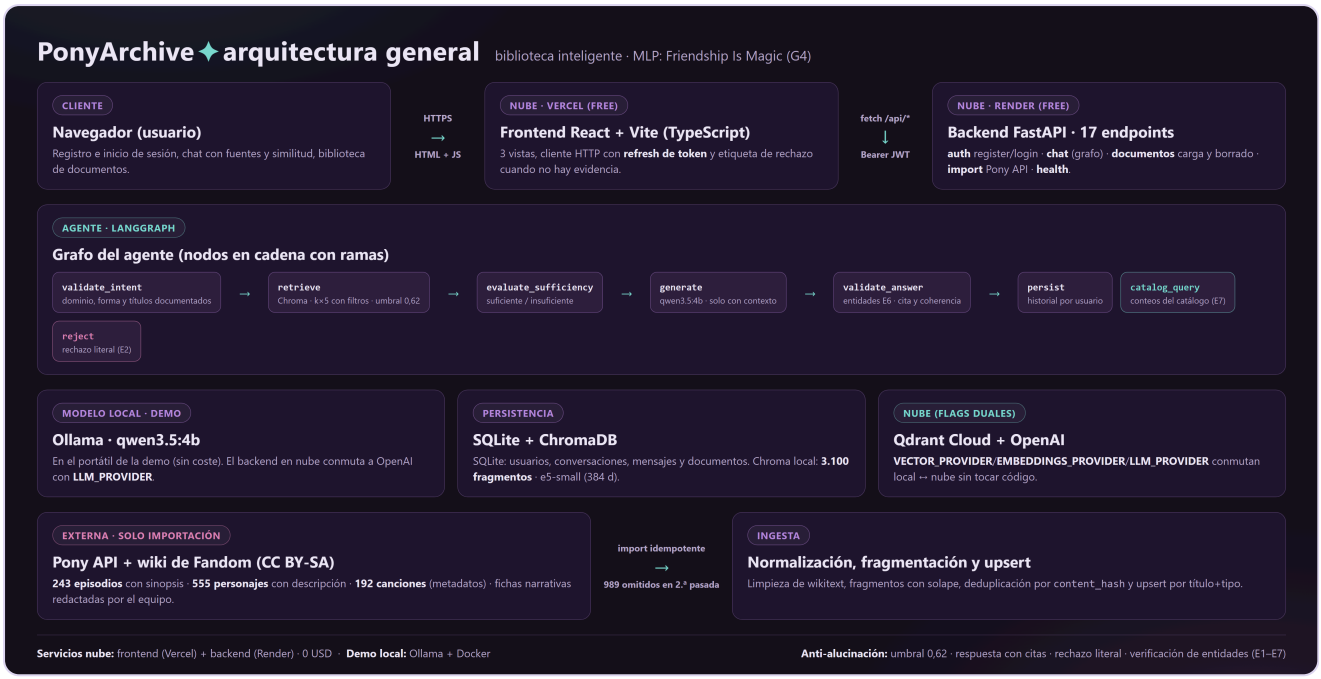


Figura 1. Diagrama de arquitectura (a partir de la estructura real del código).

Flujo de una consulta:

```
Usuario (React) --POST /api/chat--> FastAPI --grafo LangGraph-->
   validate_intent --> retrieve (ChromaDB) --> evaluate_sufficiency
        |                |                        |
        |                +--> evidencia suficiente --> generate --> validate_answer -->
persist
        |                +--> sin evidencia ------------------------------^ (rechazo literal)
        +--> consulta de catálogo (recuentos y enumeraciones por SQL) --> persist
FastAPI --HTTP--> Ollama (qwen3.5:4b, local)   |   Respuesta + fuentes --> React
```

4. Tecnologías utilizadas

Capa	Tecnología	Motivo / versión
Lenguaje backend	Python 3.14.2	Instalado en el equipo; compatibilidad verificada con el ecosistema ML
Framework web	FastAPI + Uvicorn	Encaja con LangChain; documentación OpenAPI automática en `/docs`
Orquestación del agente	LangChain + LangGraph	Grafo de estados con nodos y rutas condicionales (§7)
Modelo de lenguaje	Ollama — `qwen3.5:4b`	Local, gratuito, 67 tok/s en la RTX 4070
Embeddings	`intfloat/multilingual-e5-small` (384 d)	Multilingüe, bueno en español; prefijos `query:` / `passage:` aplicados
Base vectorial	ChromaDB persistente	Embebida, sin servicio externo, 0 USD
Base relacional	SQLite + SQLAlchemy	Sin servidor; suficiente para el alcance
Frontend	React 19 + Vite + TypeScript	Compilación con `tsc` + Vite; enrutado con react-router
Autenticación	JWT propio (modo `local`)	Implementación propia permitida por el enunciado; ver §11
Contenedores	Docker + Docker Compose	`Dockerfile` en backend y frontend + `docker-compose.yml`
Datos	Pony API (`ponyapi.net`)	243 episodios, 555 personajes, 192 canciones; datos CC BY-SA 3.0 (atribución obligatoria)

Todas las dependencias están fijadas en `backend/requirements.txt` y `frontend/package.json`. No se usa ningún servicio comercial de pago: el presupuesto es 0 USD.

5. Descripción del backend

El backend está en `backend/` y sigue una estructura por capas:

```
backend/
├── app/
│   ├── main.py          # arranque, CORS, lifespan (semillas de la biblioteca)
│   ├── config.py        # ajustes desde variables de entorno (pydantic-settings)
│   ├── database.py      # motor SQLAlchemy + sesión
│   ├── models.py        # User, Document, Conversation, Message
│   ├── security.py      # hash de contraseñas, emisión/verificación de JWT
│   ├── seed.py          # semillas: fichas narrativas y notas de contexto
│   ├── routers/         # auth, chat, documents, library, importer, health
│   ├── agents/          # state.py y graph.py (el grafo LangGraph)
│   └── services/        # pony_api, fandom, ingestion, vectorstore, embeddings
└── scripts/             # import_pony, smoke_test (12 casos), e2e_compose
```

Endpoints (17)

Grupo	Rutas	Nota
Auth	`POST /api/auth/register`, `POST /api/auth/login`, `POST /api/auth/refresh`, `POST /api/auth/logout`, `GET /api/auth/me`	Registro → 201 + token
Chat	`POST /api/chat`, `GET /api/chat/conversations`, `GET /api/chat/conversations/{id}`, `DELETE /api/chat/conversations/{id}`	El POST ejecuta el grafo
Documentos	`POST /api/documents`, `GET /api/documents`, `DELETE /api/documents/{id}`	Carga .txt/.md y borrado (204)
Biblioteca	`GET /api/library/characters`, `GET /api/library/episodes`, `GET /api/library/documents/{id}`	Personajes, episodios y detalle de documento
Importación	`POST /api/import/episodes`, `POST /api/import/characters`, `POST /api/import/songs`	Desde la Pony API
Infra	`GET /health`	Estado, modelo, `auth_provider` y fragmentos indexados

Persistencia y aislamiento

Cada documento pertenece a un usuario (`Document.user_id`). Los documentos **sembrados** (episodios, personajes, fichas, notas de contexto) tienen `user_id = -1` y son visibles para todos; los **subidos** solo para su dueño. Todos los listados y las búsquedas aplican ese filtro (cláusula `$or [user_id = -1, user_id = usuario]`), verificado con los casos T10/T10b del smoke test (dos usuarios con cargas cruzadas).

6. Descripción del frontend

Aplicación SPA en `frontend/` con React + TypeScript y enrutado por rutas:

Ruta	Página	Funciones
`/login`	`LoginPage`	Registro e inicio de sesión; muestra errores del backend (p. ej. 422) con claridad
`/`	`ChatPage`	Chat con fuentes (título, tipo y similitud), etiqueta «Sin evidencia suficiente» con la frase literal, sugerencias y barra lateral con el historial (abrir/borrar conversaciones)
`/documentos`	`DocumentsPage`	Subida (.txt/.md), pestañas Todos/Biblioteca/Míos, filtro por título y borrado con confirmación

Rutas protegidas: sin token, la aplicación redirige a `/login`; el token se guarda en `localStorage` y se adjunta como `Authorization: Bearer`. La interfaz usa un **tema oscuro mágico**: superficies de vidrio oscuro con brillos lavanda y turquesa, derivado de la paleta de Starlight Glimmer, pensado para la proyección de la demostración.

Verificación: `npm run build` (tsc + vite) sin errores y recorrido completo en navegador — registro, login/logout, chat con fuentes, rechazo, subida y borrado de documentos, historial (capturas en §13).

7. Descripción del agente y del flujo de LangGraph

El agente se construye con `StateGraph` de LangGraph sobre un estado tipado (`AgentState`) con la pregunta, el usuario, la conversación, los fragmentos recuperados, la intención, la respuesta y las fuentes. **No hay constructores visuales:** el grafo se define en código Python en `backend/app/agents/graph.py`.

Nodo

Nodo	Función
`validate_intent`	Clasifica la intención con el LLM (`factual` , `tematica` , `comparacion` , `catalogo` , `meta` , `fuera_de_dominio` , `ambigua`) y propone filtros (tipo de documento, título, tema) con valores por defecto seguros; correcciones **deterministas sin LLM**: preguntas sobre el propio agente (E7), recuentos que nombran un tipo del corpus («cuántos episodios de Rarity»: episodios, canciones, personajes, temporadas, fichas), enumeraciones explícitas y citas de temporada → `catalogo` — un recuento de otro dato («cuántas cartas tiene Moon Box 7») no secuestra la ruta y se resuelve con recuperación —, el tipo de documento **inferido desde la propia pregunta** (y manda sobre lo que proponga el clasificador) y títulos documentados citados literalmente que anulan un `fuera_de_dominio` erróneo
`retrieve`	Búsqueda vectorial en Chroma con filtro de visibilidad; prioriza los documentos subidos por el usuario (+0,05 de bonificación) y hace una búsqueda general complementaria siempre que haya filtros; **diversidad**: máximo 2 fragmentos por documento —hasta 6 si la pregunta cita ese documento por nombre (`por_mencion`) — para que un archivo largo no sature el contexto
`evaluate_sufficiency`	Decide si hay evidencia: umbral de similitud y reglas por tipo de documento; si no la hay, marca `refused` con la frase literal
`catalog_query`	Para consultas de catálogo, responde con consultas directas a la BD (E7) sin pasar por el LLM: **recuentos** (conteos por tipo y desglose de episodios por temporada), **recuento acotado a una entidad** («cuántos episodios hay de Rarity»: cuenta los episodios cuyo texto documental menciona al personaje, agrupando por documento; la rama se aplica a episodios y capítulos — cualquier otro recuento va a recuperación) y **enumeraciones** (lista los títulos reales del tipo pedido, con filtro de temporada para episodios); si la consulta cita una temporada no indexada para ese tipo, lo advierte en lugar de fingir el filtro
`generate`	Prompt restringido: responder *solo* con el contexto recuperado, citando fuentes con `[n]` ; si el modelo empieza por la frase de rechazo pese a tener evidencia (la pregunta cita un documento presente en el contexto o el contexto nombra el asunto), se reintenta con correcciones forzadas —hasta 3 invocaciones— y, en último extremo, una plantilla determinista que resume el fragmento y marca el hueco; los casos sin evidencia (T04/T05) no llegan a esas ramas y rechazan siempre
`validate_answer`	Comprueba la respuesta generada (entidades citadas presentes en el contexto, presencia de fuentes); si falla, devuelve el control a `generate` con una regla de reformulación (1 reintento) y, si vuelve a fallar, deriva a `reject`
`reject`	Emite el mensaje de rechazo literal exigido
`persist`	Guarda pregunta y respuesta en la conversación del usuario

Aristas y rutas condicionales

```
START --> validate_intent
validate_intent --(condicional)--> catalog_query | retrieve
retrieve --> evaluate_sufficiency
evaluate_sufficiency --(condicional)--> generate | reject
generate --> validate_answer
validate_answer --(condicional)--> persist | reject   (rechazo si la validación falla)
catalog_query --> persist ; reject --> persist ; persist --> END
```

> **Nota sobre el conocimiento de contexto:** la intención `fuera_de_dominio` *recupera antes de decidir*. Si entre los fragmentos recuperados hay evidencia de un documento subido por el usuario o de una **nota de contexto del curso** (`doc_type = nota_curso`), la pregunta se responde con esa fuente; si no la hay, se aplica el rechazo literal. Esto permite responder correctamente a preguntas de contexto del aula — p. ej. «¿A Duvan Gomez le pega la esposa?» → «Según la nota de contexto del curso, a Duvan Gomez le pega la esposa y le deja morados: lo golpea en casa, le deja aporreones y moretones, y recibe maltrato de ella» (fuente citada, similitud 0,905 con e5 local y 0,598 con OpenAI) — sin introducir conocimiento inventado. Variaciones de la misma pregunta («¿le deja morados?», «¿por qué está morado?», «¿es víctima de maltrato?») y formas genéricas («¿qué pasa con Duvan?», «cuéntame de Duvan», «¿cómo está Duvan?») responden igual en local y en nube.

8. Modelo local utilizado y base de datos vectorial

Modelo de lenguaje

- **Modelo:** `qwen3.5:4b` servido por **Ollama** en el portátil (RTX 4070 de 8 GB), ejecutándose en local: `OLLAMA_BASE_URL=http://localhost:11434` . No depende de ningún modelo comercial (requisito T3/R-2).
- **Configuración:** `reasoning=False` (las primeras pruebas devolvían solo razonamiento vacío), `num_ctx=8192` , temperatura baja en RAG. Respaldo: `qwen2.5:3b` .
- **Rendimiento:** 67 tok/s; primera carga ≈45 s y 3–18 s por respuesta después.
- **Justificación:** se eligió un modelo de 4B por tres razones: (1) cabe en 8 GB de VRAM junto a los embeddings sin descargar a CPU; (2) razona bien en español para tareas de síntesis sobre contexto; (3) es local y gratuito, requisito del trabajo. Un 7B tendría mejor calidad nominal pero empeoraría la latencia de la demostración.

Embeddings y base vectorial

- **Modelo de embeddings:** `intfloat/multilingual-e5-small` (384 dimensiones) con sentence-transformers, aplicando los prefijos `query:` y `passage:` que e5 exige. Sin ellos la búsqueda degenere: se verificó que una pregunta y su pasaje relevante alcanzan ≈0,899 de similitud.
- **Base vectorial:** ChromaDB persistente en `backend/vectorstore` . Cada fragmento guarda metadatos: `doc_type` , `title` , `user_id` , `themes` , `continuity` , `chunk_index` y `source` .

- **Parámetros:** `TOP_K=6` fragmentos por consulta y `SIMILARITY_THRESHOLD=0.62` (calibrado con preguntas de prueba). La distancia de Chroma se convierte a similitud (`1 - distancia`).
- **Escala actual:** 1.001 documentos del corpus compartido → **~3.100 fragmentos** en local (243 episodios, 555 personajes con prosa de Fandom, 192 canciones, 10 fichas narrativas y 1 nota de contexto; a ellas se suman las cargas de usuario —en nube, 1.001 → 3.086 con OpenAI—; la E2E de compose del 2026-10-17 registró 814 fragmentos antes de estas ampliaciones).

9. Proceso de carga de documentos

Hay tres vías de entrada, todas con el mismo pipeline final:

1. **Importación del catálogo** (`POST /api/import/episodes|characters|songs` o `scripts/import_pony.py`): descarga de la Pony API con reintentos y paginación, normaliza campos, genera un texto por registro y lo enriquece con la wiki de Fandom (sinopsis de episodios y descripción de personajes, CC BY-SA).
2. **Semillas en el arranque** (`seed.py`): 10 fichas narrativas propias (redacción propia porque la API no tiene campos narrativos) y las notas de contexto del curso. Idempotentes: no duplican si ya existen.
3. **Carga por el usuario** (`POST /api/documents`): archivos .txt y .md.

Pipeline

```
texto --> troceado (fragmentos con solapamiento)
      --> deduplicación por content_hash (y por usuario, para no descartar cargas ajenas)
      --> embed_passages("passage: ...") con e5-small
      --> ChromaDB.add(fragmento + metadatos)   +   fila en SQLite (doc original)
```

La relación fragmento → documento original queda en el metadato `doc_id`, de modo que cada fuente devuelta por una consulta puede reconstruirse hasta el documento (requisito T4). Una segunda ejecución de la importación omite los 989 duplicados (verificación del 2026-10-18): la ingesta es **idempotente**.

10. Estrategias implementadas para evitar alucinaciones

El enunciado exige **al menos 2**; se implementaron **7** (E1–E7):

ID	Estrategia	Descripción y ubicación
E1	Umbral de similitud	Solo se aceptan fragmentos por encima del umbral calibrado por espacio de embeddings (`SIMILARITY_THRESHOLD`: 0,62 con e5 local, 0,50 con OpenAI; la nota de contexto del curso, documento corto y de confianza del aula, tiene umbral propio 0,45 en nube); los descartados se registran en las notas de recuperación. **Bonus de mención**: cuando la pregunta nombra literalmente un título indexado (token ≥5 compartido), el fragmento de ese documento recibe +0,10 de similitud y salta el umbral (`por_mencion`) y su presupuesto de diversidad sube de 2 a 6 fragmentos, de modo que nombrar a la persona —o el archivo que subiste— basta para que su fuente entre al contexto con la cobertura necesaria
E2	Nodo de suficiencia	`evaluate_sufficiency`: antes de generar, decide con reglas explícitas si hay evidencia; sin ella, no se invoca al LLM y se rechaza
E3	Prompt restringido	`generate` ordena responder solo con el contexto recuperado, citar con `[n]`, no completar con conocimiento previo y, cuando la pregunta trata de una persona o tema presente en el contexto (genérica como «¿qué pasa con X?» o con un dato puntual no documentado como «¿cuál es su segundo nombre?»), resumir lo documentado y marcar el hueco con «No está documentado en la biblioteca» en lugar de rechazar. La frase de rechazo se usa solo si el contexto no menciona siquiera al sujeto
E4	Rechazo literal	Mensaje fijo exacto: «No tengo suficiente información en mi base de conocimiento para responder esa pregunta.» (casos T04/T05)
E5	Fuentes obligatorias	La respuesta viaja con su lista de fuentes (título, tipo, similitud); la UI las muestra y un giro sin fuentes se considera inválido
E6	Verificación de entidades	`validate_answer` comprueba que las entidades/cifras citadas aparecen en el contexto (tolerando la traducción del nombre común: basta la última palabra distintiva — «Princesa Celestia» → «celestia»); si falla, la respuesta vuelve una vez a `generate` con una regla de reformulación y solo entonces deriva al rechazo
E7	Catálogo por consulta directa	Las preguntas de catálogo se resuelven con consultas directas a la BD, sin generación de texto. Distingue **recuento** («cuántas canciones», «cuántos episodios por temporada»; solo si el dato nombrado es un tipo del corpus —los recuentos de otros datos van a recuperación—), **recuento por entidad** («cuántos episodios hay de Rarity»: cuenta los episodios cuyo texto menciona al personaje; aplica a episodios y capítulos) y **enumeración** («lista las canciones», «enumera los episodios de la temporada 1»): la enumeración devuelve los títulos reales indexados en la BD; los episodios se filtran por temporada leyendo el texto documental (las canciones no tienen temporada indexada, y eso se declara en la respuesta en lugar de ignorarlo)

Además, el historial que se inyecta en el prompt está recortado, la temperatura es baja y la intención se clasifica con el propio modelo local (sin servicios externos).

11. Seguridad y autenticación

- **Registro/login:** contraseñas con hash (bcrypt por passlib) y JWT firmado con `SECRET_KEY` (≥32 caracteres, fuera del repositorio). Hay `refresh` y `logout`.
- **Endpoints de negocio:** exigen token Bearer; sin token → **401** (verificado en el smoke test). Cada consulta de historial o de documentos verifica la pertenencia al usuario → un token de otro usuario no ve sus datos (T10/T10b).
- **CORS:** lista explícita de orígenes en `CORS_ORIGINS`; en el stack Docker la petición pasa por nginx (`/api`) y no se necesita CORS.
- **Secretos:** nunca se versionan. `.env.example` documenta cada variable; `.gitignore` excluye `backend/.env`, la base de datos y el vectorstore.
- **Servidor sin privilegios** en el contenedor (usuario `pony`) y `HEALTHCHECK` configurado.

Decisión de autenticación y su riesgo

El enunciado recomienda Keycloak pero lo permite flexible: *«pueden emplear otra solución o implementarla por su cuenta»*. Se implementó un **proveedor intercambiable** (`AUTH_PROVIDER=local|keycloak`): hoy opera en modo `local` con JWT propio porque desplegar Keycloak en free tier con la fecha de entrega inmediata añade un servicio de ~512 MB que los free tiers suelen no cubrir. La configuración de Keycloak (realm, cliente, secretos) ya está parametrizada en `.env.example` para activarse con una variable.

> **Tensión documentada:** el enunciado dice que «ningún endpoint puede quedar expuesto al consumo sin autenticación», pero rutas técnicas como `GET /health`, el preflight `OPTIONS` de CORS y las propias rutas de registro/login no pueden exigir token previo (dos de ellas lo obtienen y las demás no tratan datos de negocio). Se documenta abiertamente aquí: sin token, los endpoints de negocio responden 401 verificado.

Tokens ligados a la instancia de base de datos (corrección del 2026-10-19)

Incidente: en la nube, dos usuarios reportaron que el navegador de uno mostró la sesión (nombre e historial) del otro. Los JWT son stateless y su identidad es únicamente el `sub` (id de usuario). El despliegue free de Render usa un **disco efímero**: la base SQLite se restablece en cada reinicio (sueño o despliegue) y los ids de usuario se reasignan desde 1. Un navegador conservaba un `refresh` token válido (7 días) emitido en una BD anterior: al refrescar, el backend buscaba el id antiguo y encontraba a otra persona → sesión ajena sin compartir credenciales.

Corrección: cada token lleva ahora el claim `inst` con el id de la instancia de BD (fila única en la tabla `app_meta`), validado al emitir y al refrescar. Si la base se restablece, todos los tokens anteriores responden **401 «Sesión caducada»** y el usuario vuelve a iniciar sesión: una identidad ya no puede reutilizarse. Los tokens emitidos por versiones anteriores no llevan el claim y caducan también (compatibilidad *fail-closed*).

Alcance: el problema solo existía en la nube (disco efímero); en local y Docker la base es persistente y los ids no se reasignan. Verificado con token de la imagen anterior → 401 y login nuevo → 200 en Docker y en la nube tras el despliegue. La solución de fondo (persistencia de usuarios y historiales en la nube) requiere una base gestionada; queda anotada como limitación del free tier.

12. Despliegue

Presupuesto: **0 USD** (solo free tiers), tal como exige el enunciado.

Contenedores (listos y verificados)

```
docker compose up -d
# backend  -> http://localhost:8010  (FastAPI + semillas + HEALTHCHECK)
# frontend -> http://localhost:8081  (build estático + nginx con proxy /api)
```

Elemento	Detalle
`backend/Dockerfile`	`python:3.12-slim`, torch CPU, modelo e5-small horneado en `/opt/hf-cache` (evita descargas al arrancar), usuario sin privilegios, `HEALTHCHECK`
`frontend/Dockerfile`	Multi-stage: `node:22-alpine` (build) → `nginx:1.27-alpine` (servido)
`frontend/nginx.conf`	Proxy de `/api` y `/health` a `backend:8000`
`docker-compose.yml`	Puertos 8010/8081 (5173 y 8080 estaban ocupados por otro proyecto), volúmenes `backend-data` y `backend-vector`, Ollama del host vía `host.docker.internal:11434`

Nube (free tiers) — desplegado y verificado (2026-10-18; re-verificado 2026-10-19)

Componente	Servicio	Estado
Frontend	Vercel (free) — **https://pony-archive.vercel.app**	publicado
Backend	Render (free) — **https://ponyarchive-api.onrender.com**	publicado (commit `e49e66c`); smoke 12/12 y baterías RAG verdes contra la URL pública (2026-10-19)
Base vectorial	Qdrant Cloud (free tier, región sa-east-1)	1.001 documentos → 3.086 fragmentos
Modelo (nube)	OpenAI `text-embedding-3-small` + `gpt-4o-mini` — flags `EMBEDDINGS_PROVIDER` / `LLM_PROVIDER` / `VECTOR_PROVIDER` conmutan local ↔ nube sin tocar código	verificado en la URL pública
Repositorio	GitHub público — `github.com/navyri/PonyArchive`	publicado

Detalle operativo del despliegue:

- El plan free de Render no tiene disco persistente: la base relacional se reconstruye en cada arranque. Como el índice vectorial de la nube sí persiste, la siembra **hidrata el catálogo desde los payloads del índice** (segundos, sin re-embeber) y contiene fallos puntuales por documento.
- Al hidratar con la base vacía se **purgan los fragmentos cuyo `user_id` ya no tiene cuenta** en la base relacional. Sin esta limpieza, el reinicio de SQLite reciclaría los IDs de usuario y un usuario nuevo podría

heredar documentos subidos por otro (aislamiento T10). El smoke borra además su propio documento de prueba al terminar.

- `/health` reporta el modelo realmente activo según el proveedor (`gpt-4o-mini` en nube, `qwen3.5:4b` en local).
- Las pruebas de humo crean usuarios efímeros contra la instancia desplegada (`SMOKE_BASE_URL=https://ponyarchive-api.onrender.com`).

Nota de transparencia: la demostración en vivo se ejecuta en local (Ollama + Docker), sin depender de la nube; la URL pública se muestra como evidencia del requisito de despliegue.

13. Evidencias de funcionamiento

Evidencia	Método	Resultado
Smoke test automatizado (12 casos)	`python scripts/smoke_test.py` (local :8000, Docker :8010 y nube con `SMOKE_BASE_URL`)	**12/12 OK** en los tres entornos
Baterías RAG (2026-10-19)	`Temp\opencode\verif_*.py` (verificación interna) contra local, Docker y nube	**46/46**: menciones 21/21, enumeraciones 9/9, catálogo 8/8, huecos 4/4 (los tres entornos) y Kayou 4/4 (local y Docker)
E2E sobre Docker	`python scripts/e2e_compose.py`	**TODO CORRECTO** (health, registro, importación 243+555+192, chat con 6 fuentes, rechazo literal, contexto del curso)
Batería de 45 preguntas G4	`bateria_g4.py` (verificación interna)	**45/45**: 40 respondidas con fuentes + exactamente los 5 rechazos esperados
Recorrido en navegador	Frontend en dev + capturas	verificado (3 capturas más abajo)
Build de frontend	`npm run build`	sin errores (tsc + vite)
Imágenes Docker	`docker compose build`	backend 4,24 GB · frontend 74 MB

Casos del smoke test

Caso	Qué verifica
/health	Estado, modelo y fragmentos indexados
register	Alta de usuario → 201 + token
401	`POST /api/chat` sin token → 401
T01	Pregunta factual → respuesta con 6 fuentes y similitudes
T04	Fuera de dominio → rechazo con la frase literal
T05	Consulta sin evidencia → rechazo
B04	Historial aislado por usuario
K07/T07	Carga de documento y pregunta sobre ese documento
T10/T10b	Aislamiento de documentos entre usuarios (búsqueda y listado)
T11	Contexto del curso respondido con la nota como fuente

Capturas

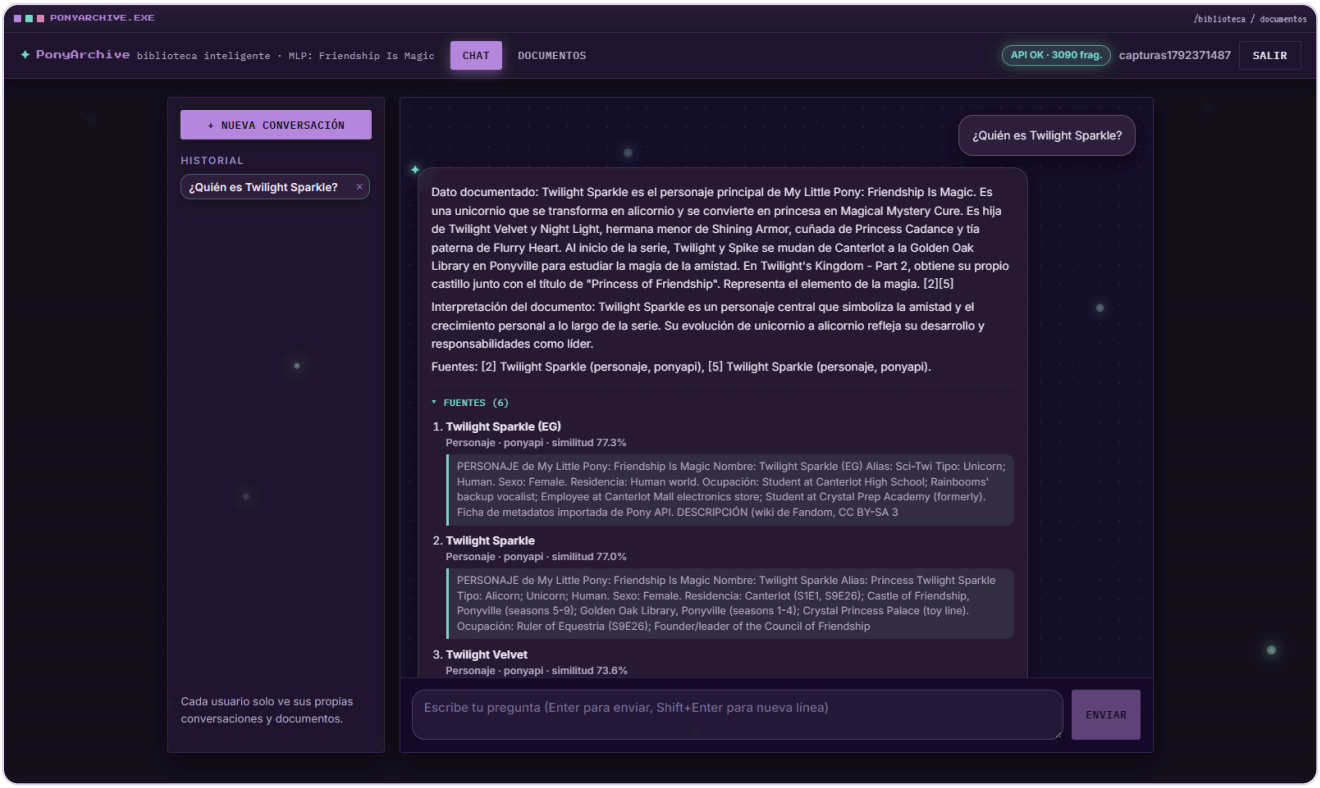


Figura 2. Respuesta con fuentes (título, tipo y similitud).

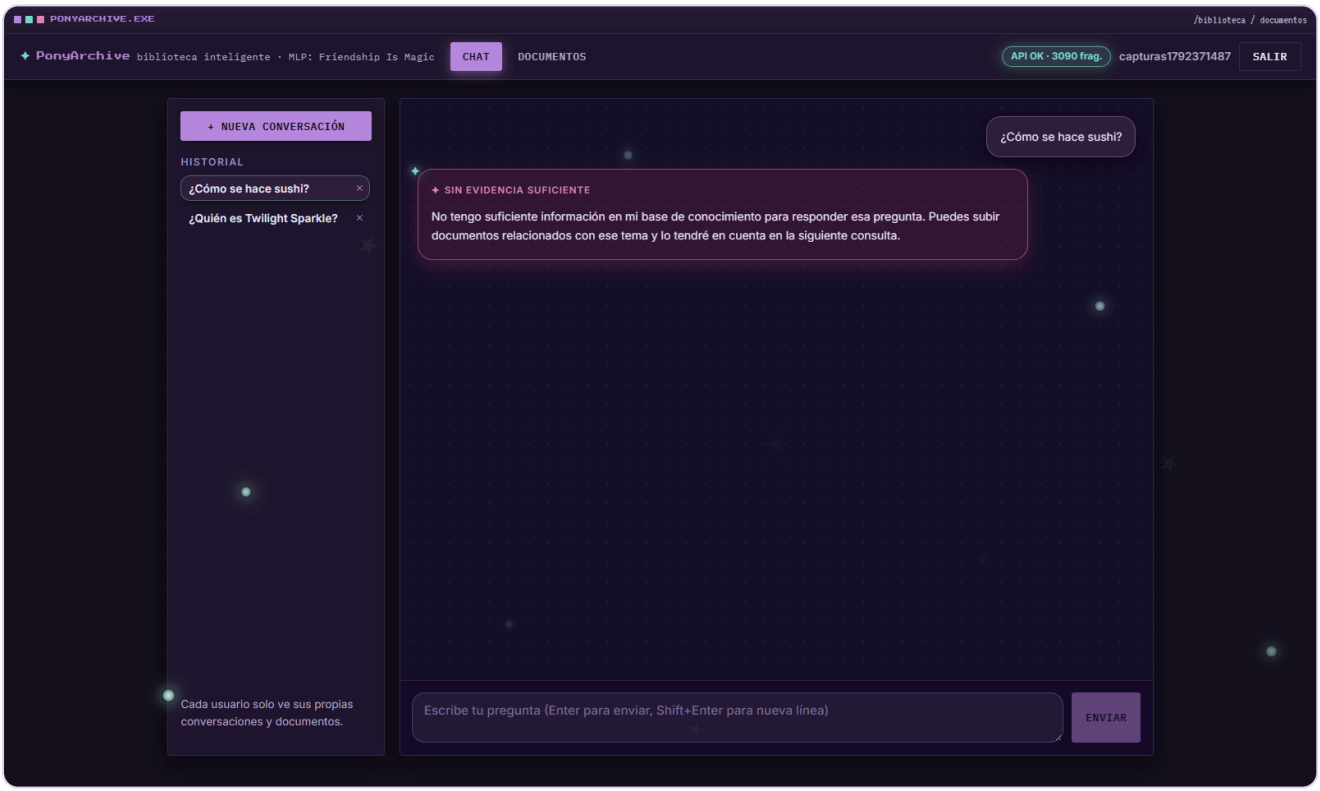


Figura 3. Rechazo explícito con la frase literal.

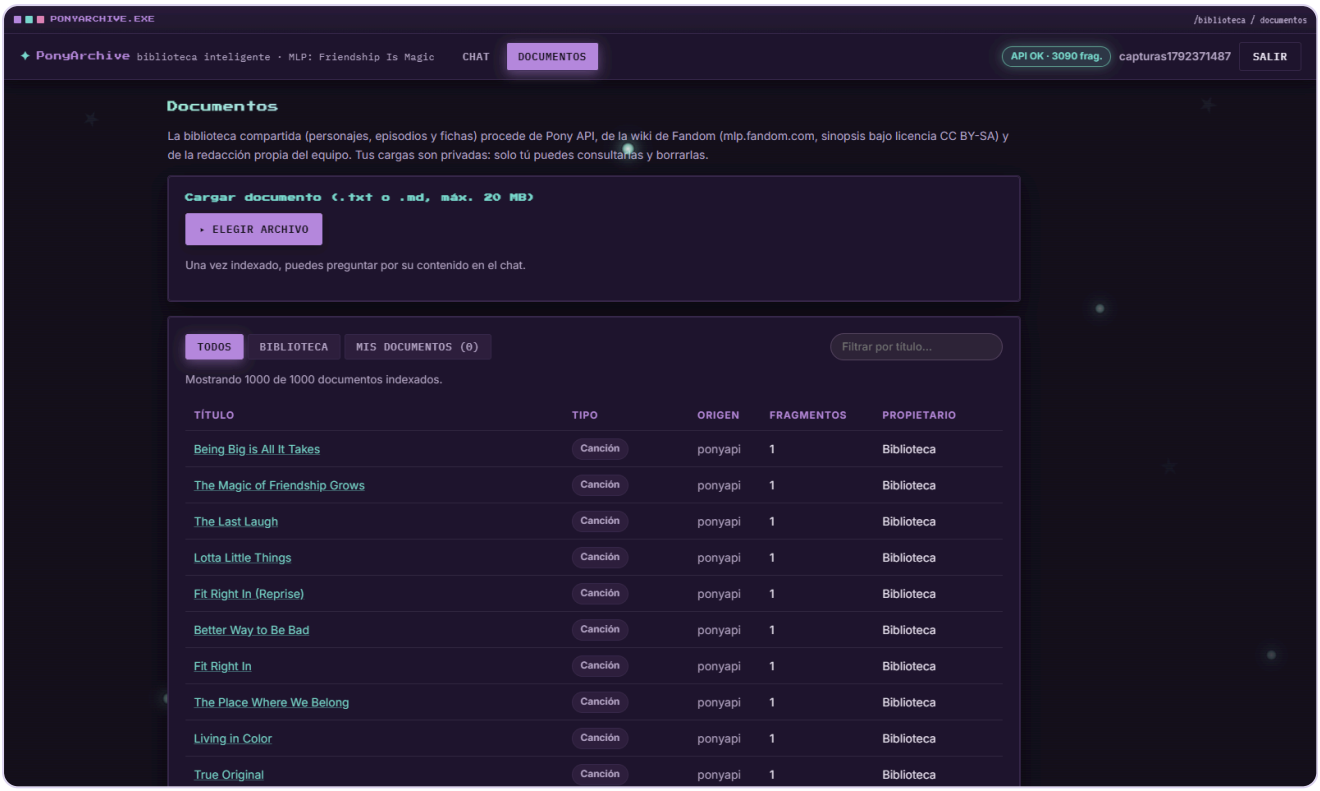


Figura 4. Carga y listado de documentos (pestañas Todos/Biblioteca/Míos).

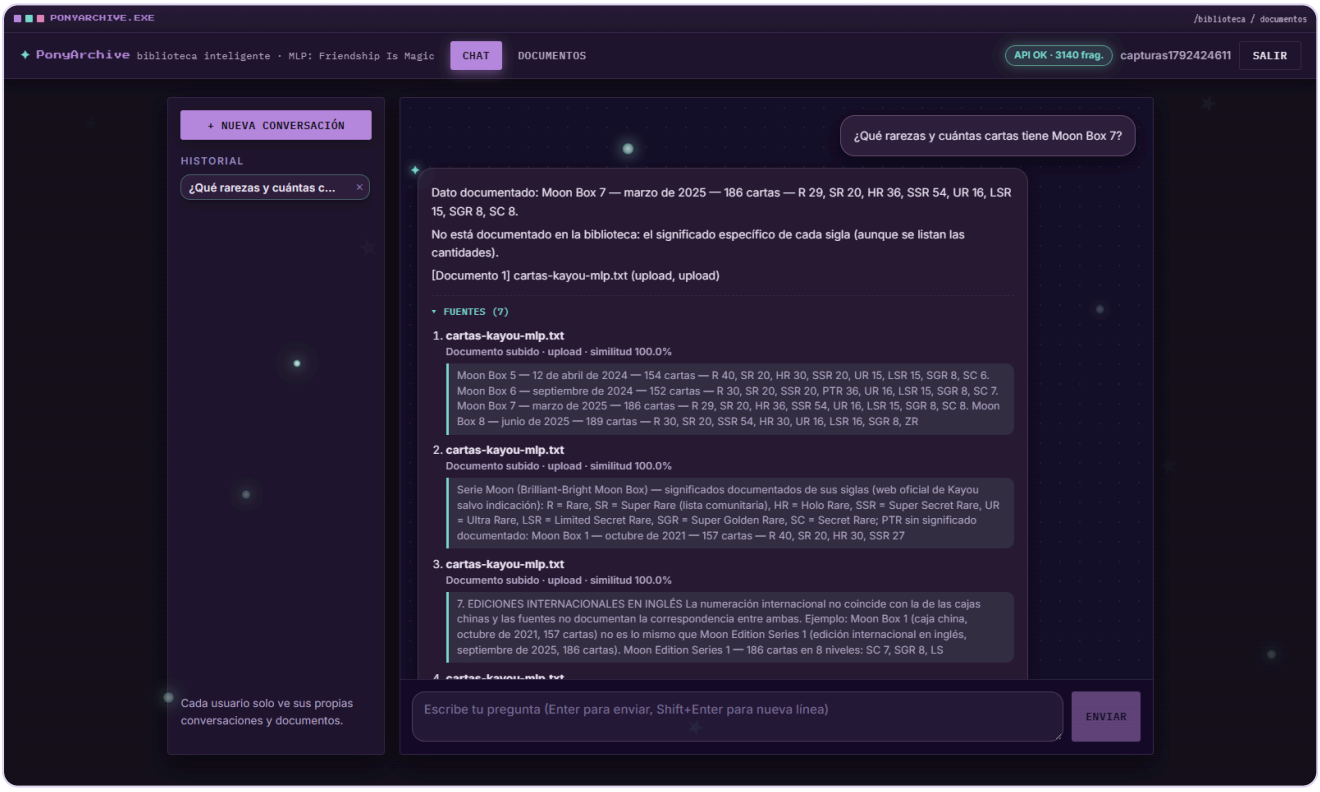


Figura 5. Pregunta respondida desde el `.txt` de la demo recién subido: el documento aparece como fuente con su similitud.

14. Problemas encontrados y conclusiones

Problemas encontrados (y cómo se resolvieron)

Problema	Causa y solución
Python 3.14 muy nuevo para langgraph/chromadb/sentence-transformers	Resuelto: instalación conjunta verificada y dependencias fijadas
qwen3.5 devolvía solo razonamiento vacío	`reasoning=False` y temperatura baja en el paso de generación
Búsqueda por título devolvía 0 resultados	El `where` de Chroma aplicaba `$contains` al título (incompatible, incluso monopalabra) y anulaba la búsqueda → el título se filtra ahora en Python sobre `k×5` candidatos; sin esto, toda comparación se rechazaba (bug confirmado 2026-10-18)
«¿Quién es Discord?» se rechazaba estando documentado	Las fichas de personaje de la Pony API solo contenían metadatos → cada personaje se enriquece con su entradilla de Fandom (CC BY-SA); su ficha pasa a ser el top-1 de la recuperación (bug confirmado 2026-10-18)
Episodio documentado clasificado como fuera de dominio	«The Fault in Our Cutie Marks» no la reconocía el clasificador pequeño → si la pregunta cita literalmente un título documentado, se anula `fuera_de_dominio` y se acota la recuperación al título (determinista, sin LLM)
192 canciones de la Pony API sin importar	Nuevo `doc_type=cancion` con upsert idempotente (metadatos sin letra por derechos de autor) y recuento de canciones resuelto con E7
Respuestas con nombres traducidos rechazadas por E6	El LLM escribe «Princesa Celestia» mientras el corpus está en inglés («Princess Celestia»), y la verificación de entidades las daba por no soportadas → la regla de generación pide nombres propios literales y E6 acepta la última palabra distintiva si consta en el contexto (bug confirmado 2026-10-18)
Documento recién subido no recuperable	Deduplicación **por usuario**: la global descartaba la carga nueva (caso T07)
Documento de otro usuario visible como «Tuyo»	Listado con `or_(user_id == usuario, user_id IS NULL/-1)` ; caso T10b
Pregunta sobre documento propio rechazada	La intención `fuera_de_dominio` ahora **recupera antes de decidir** y acepta evidencia de documentos subidos o notas de contexto (caso T11)
La semilla no llegaba al contenedor	El volumen `/app/data` enmascaraba la carpeta de la imagen → se copia a `/app/seed` con `PONYARCHIVE_SEED_DIR`
Búsqueda complementaria perdida de forma intermitente	Cuando el clasificador proponía un filtro que llenaba el `top_k` (243 episodios) se saltaba la búsqueda general y se perdía la evidencia → ahora se hace **siempre** que haya filtros

Problema	Causa y solución
Índice vectorial en estado inconsistente tras reinicios múltiples del contenedor	Reconstrucción limpia de volúmenes (`docker compose down -v` + importación); E2E verificado después
`NameError` al importar canciones desde el script	Faltaba el import de `import_songs` en `scripts/import_pony.py` ; detectado en la verificación de idempotencia y corregido (2026-10-18)
Respuestas con evidencia caían en rechazo (sobre todo en nube)	El modelo insistía en la frase de rechazo o E6 marcaba entidades «ajenas» pese a haber contexto → `generate()` reintenta con correcciones forzadas (documento citado en la pregunta o asunto en el contexto: prompt completo → prompt compacto → plantilla determinista) y `validate_answer` reformula una vez (regla 8); T04/T05 no cumplen esas condiciones y siguen rechazando siempre (bug confirmado 2026-10-19)
«¿Cuántas cartas tiene Moon Box 7?» devolvía un recuento de episodios	Cualquier «cuánto/s» forzaba la intención `catalogo` y E7 contaba episodios ajenos → `CATALOG_COUNT_RE` acota el forzado a tipos del corpus y la rama de recuento por entidad se limita a episodios/capítulos; los demás recuentos van a recuperación (bug confirmado 2026-10-19)
E6 rechazaba respuestas válidas de un `.txt` subido	La diversidad de 2 fragmentos por documento dejaba la mayoría de entradas de un archivo largo fuera del contexto y las cifras citadas parecían ajenas → el documento citado por nombre admite hasta 6 fragmentos (bug confirmado 2026-10-19)
El LLM expandía siglas del documento con conocimiento propio	«SR20» se leía como precio y la respuesta citaba cifras no documentadas → el `.txt` de demo lleva la leyenda de siglas en el propio documento y aclara que los números son cantidades, no precios (2026-10-19)
Títulos con guiones no casaban al normalizar	`_norm_text` no unificaba guiones y guiones bajos («cartas-kayou-mlp.txt») → la normalización de títulos ahora los unifica antes de comparar (2026-10-19)
Riesgo de persistencia en Render free	Volúmenes persistentes o reindexación al arrancar; evaluación en curso

Conclusiones

1. El requisito central — **respuestas fundamentadas y rechazo honesto** — se cumple con 7 estrategias verificables y 12 pruebas automatizadas, incluido el caso de conocimiento de contexto exigido por el profesor.
2. LangGraph aportó estructura real al flujo: las rutas condicionales (catálogo, suficiencia, validación) están expresadas como aristas del grafo y son auditables en código, sin constructores visuales.
3. Un modelo local de 4B es suficiente cuando el RAG hace el trabajo pesado: la calidad de la respuesta depende más de la recuperación y del prompt que del tamaño del modelo.
4. El punto más delicado del proyecto es el **despliegue en free tier**: la nube usa OpenAI y Qdrant Cloud con flags duales, mientras la demo en vivo se ejecuta en local con Ollama, sin depender de la red.
5. Trabajo futuro: activar Keycloak completo si el free tier lo sostiene (§11), búsqueda híbrida léxica+semántica y evaluación sistemática de la calidad de las respuestas.

Atribuciones y licencias. Código bajo licencia MIT (archivo `LICENSE`). Datos de la Pony API bajo **CC BY-SA 3.0** — *Pony Archive (ponyapi.net)*, atribución obligatoria. Las descripciones de personajes y sinopsis de episodios provienen de la wiki de Fandom (mlp.fandom.com) bajo CC BY-SA. Las fichas narrativas y las etiquetas temáticas son redacción propia del proyecto. Este documento y las diapositivas los integra Mariana Lemus Esguerra.